Proyecto final

November 9, 2024

1 Detección de fraudes con tarjetas de crédito

Enlace al dataset: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

1.0.1 Importa las bibliotecas necesarias

[1]:
```
# Importa la bibliotecas necesarias
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, accuracy_score
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings("ignore")
```

1.0.2 Importa y organiza el dataset

[13]:
```
# Organizar los datos en un dataframe
dataset = pd.read_csv('creditcard.csv')
print(dataset.head())
```

```
   Time        V1        V2        V3        V4        V5        V6        V7  \
0   0.0 -1.359807 -0.072781  2.536347  1.378155 -0.338321  0.462388  0.239599
1   0.0  1.191857  0.266151  0.166480  0.448154  0.060018 -0.082361 -0.078803
2   1.0 -1.358354 -1.340163  1.773209  0.379780 -0.503198  1.800499  0.791461
3   1.0 -0.966272 -0.185226  1.792993 -0.863291 -0.010309  1.247203  0.237609
4   2.0 -1.158233  0.877737  1.548718  0.403034 -0.407193  0.095921  0.592941

         V8        V9  …       V21       V22       V23       V24       V25  \
0  0.098698  0.363787  … -0.018307  0.277838 -0.110474  0.066928  0.128539
1  0.085102 -0.255425  … -0.225775 -0.638672  0.101288 -0.339846  0.167170
2  0.247676 -1.514654  …  0.247998  0.771679  0.909412 -0.689281 -0.327642
3  0.377436 -1.387024  … -0.108300  0.005274 -0.190321 -1.175575  0.647376
```

```
4 -0.270533  0.817739  … -0.009431  0.798278 -0.137458  0.141267 -0.206010

        V26       V27       V28  Amount  Class
0 -0.189115  0.133558 -0.021053  149.62      0
1  0.125895 -0.008983  0.014724    2.69      0
2 -0.139097 -0.055353 -0.059752  378.66      0
3 -0.221929  0.062723  0.061458  123.50      0
4  0.502292  0.219422  0.215153   69.99      0

[5 rows x 31 columns]
```

Haz clic aquí para obtener una pista

```
Comienza por importar la biblioteca de pandas: import pandas as pd.

Utiliza la función read_csv() para cargar el archivo CSV en un dataframe de pandas. Especifica

Asigna al dataframe resultante al nombre de una variable, por ejemplo: data = pd.read_csv("ruta

Utiliza el método head() sobre el dataframe para mostrar las primeras 10 filas, por ejemplo: da

Asegúrate de reemplazar "ruta_al_archivo.csv" con la ruta real a tu archivo y el nombre de tu a
```

1.0.3 Limpia los datos

a. Valores perdidos

[15]:
```
print(dataset.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 284807 entries, 0 to 284806
Data columns (total 31 columns):
 #   Column  Non-Null Count   Dtype
---  ------  --------------   -----
 0   Time    284807 non-null  float64
 1   V1      284807 non-null  float64
 2   V2      284807 non-null  float64
 3   V3      284807 non-null  float64
 4   V4      284807 non-null  float64
 5   V5      284807 non-null  float64
 6   V6      284807 non-null  float64
 7   V7      284807 non-null  float64
 8   V8      284807 non-null  float64
 9   V9      284807 non-null  float64
 10  V10     284807 non-null  float64
 11  V11     284807 non-null  float64
 12  V12     284807 non-null  float64
 13  V13     284807 non-null  float64
 14  V14     284807 non-null  float64
```

```
 15  V15     284807 non-null  float64
 16  V16     284807 non-null  float64
 17  V17     284807 non-null  float64
 18  V18     284807 non-null  float64
 19  V19     284807 non-null  float64
 20  V20     284807 non-null  float64
 21  V21     284807 non-null  float64
 22  V22     284807 non-null  float64
 23  V23     284807 non-null  float64
 24  V24     284807 non-null  float64
 25  V25     284807 non-null  float64
 26  V26     284807 non-null  float64
 27  V27     284807 non-null  float64
 28  V28     284807 non-null  float64
 29  Amount  284807 non-null  float64
 30  Class   284807 non-null  int64
dtypes: float64(30), int64(1)
memory usage: 67.4 MB
None
```

[17]:
```
print(dataset.isnull().sum())
```

```
Time      0
V1        0
V2        0
V3        0
V4        0
V5        0
V6        0
V7        0
V8        0
V9        0
V10       0
V11       0
V12       0
V13       0
V14       0
V15       0
V16       0
V17       0
V18       0
V19       0
V20       0
V21       0
V22       0
V23       0
V24       0
V25       0
```

```
V26       0
V27       0
V28       0
Amount    0
Class     0
dtype: int64
```

[19]:
```
dataset.fillna(dataset.mean(), inplace=True) #Eliminar nulos
```

Haz clic aquí para obtener una pista

```
Utiliza el nombre de la variable del dataframe seguido del método isnull() para crear un datafi

Utiliza el método sum() en el dataframe booleano para contar la cantidad de valores verdaderos

Si unes ambos pasos, el código se verá así: data.isnull().sum()


Este código asume que el nombre del datafrme de pandas es «data». Si tu dataframe tiene un nomb
```

b. Datos duplicados

[23]:
```
dataset.duplicated().sum()
```

[23]:
```
1081
```

[25]:
```
#Elimino los duplicados
dataset = dataset.drop_duplicates()
```

Haz clic aquí para obtener una pista

```
Usa el nombre de la variable del dataframe seguido del método duplicated() para crear un datafi

Usa el método sum() en el dataframe booleano para contar la cantidad de valores verdaderos (i.e

Si unes ambos pasos, el código se verá así: data.duplicated().sum()

Este código asume que el nombre del dataframe de pandas es «data». Si tu dataframe tiene un nom
```

1.0.4 Analiza los datos

Pregunta 1: ¿Cuál es el porcentaje de transacciones fraudulentas en el dataset?

[27]:
```
#Calcula el porcentaje de transacciones fraudulentas
transacciones = len(dataset)
numero_transacciones_fraudulentas = dataset['Class'].sum()
#No hace falta usar un condicional para class=1 lo hayo directamente con la␣
 ↪suma ya que Class tiene valores 1 para fraude y 0 para no fraude.
fraude = (numero_transacciones_fraudulentas / transacciones) * 100
```

```
#Muestra el porcentaje de transacciones fraudulentas
print(fraude)
```

```
0.1667101358352777
```

Haz clic aquí para obtener una pista

Para calcular el porcentaje de transacciones fraudulentas, debes contar la cantidad de transacciones fraudulentas (aquellas donde «Class» es igual a 1) y dividirla por le número total de transacciones en el dataset. Después, multiplica el resultado por 100 para obtener el porcentaje.

Pregunta 2: ¿Cuál es el importe medio de las transacciones fraudulentas?

[29]:
```
#Seleccionando solo las filas donde la columna Class es igual a 1
transacciones_fraudulentas = dataset[dataset['Class'] == 1]
#Este método calcula la media (promedio) de los valores en la columna Amount
importe_medio_fraude = transacciones_fraudulentas['Amount'].mean()
#Muestra el importe medio
print(importe_medio_fraude)
```

```
123.87186046511628
```

Haz clic aquí para obtener una pista

Para calcular el importe medio de las tansacciones fraudulentas, primero deberás filtrar el dataset para que contenga solamente las transacciones fraudulentas (aquellas donde «Class» es igual a 1) y, después, calcular la media de la columna «Amount» de los datos filtrados.

1.0.5 Visualiza los datos

Pregunta 1: ¿Cuántas transacciones fraudulentas hay en comparación con las no fraudulentas? (Utiliza un gráfico de barras)

[34]:
```
#Cuenta la cantidad de 0s y 1s en la columna Class, devolviendo una Series de␣
 ↪transacciones fraudulentas y no fraudulentas
numero_de_fraude = dataset['Class'].value_counts()

#Crear el gráfico de barras
#Configuro el tamaño, tipo de grafico y sus colores
plt.figure(figsize=(6,4))
numero_de_fraude.plot(kind='bar', color=['blue', 'red'])
#titulos
plt.title('Transacciones fraudulentas vs Transacciones no fraudulentas')
plt.xlabel('0 = No Fraudulenta 1 = Fraudulenta')
plt.ylabel('Cantidad de Transacciones')
#Asigno las etiquetas a los valores 0 y 1,incluyo rotation=0 para usar el eje x.
plt.xticks([0, 1], ['No Fraudulentas', 'Fraudulentas'], rotation=0)
plt.show()
```

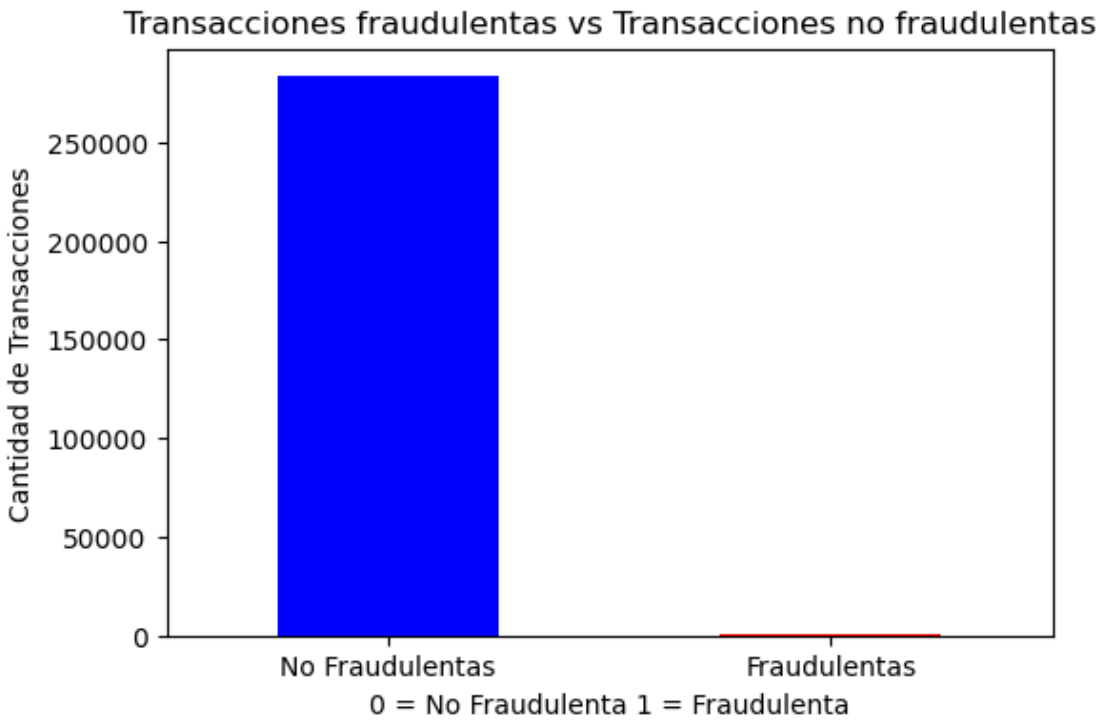

Haz clic aquí para obtener una pista

Para crear un gráfico de barras que muestre la cantidad de transacciones fraudulentas y no fraudulentas, deberás contar las veces que ocurre cada clase (fraude y no fraude) según la información de la columna «Class» y después representar estos recuentos en un gráfico de barras.

Pregunta 2: ¿Cuál es la distribución de los importes de las transacciones fraudulentas? (Utiliza un histograma)

[38]:
```
plt.figure(figsize=(8,6)) #Tamaño
plt.hist(transacciones_fraudulentas['Amount'], bins=100, color='red',␣
 ↪edgecolor='black') #columna y color
plt.title('Distribución Transacciones Fraudulentas')  #Título del gráfico
plt.xlabel('Importe de la Transacción')  #Título del eje X
plt.ylabel('Frecuencia')  #Título del eje Y
plt.grid(True)  #Añadir una cuadrícula para la lectura
plt.show()
```

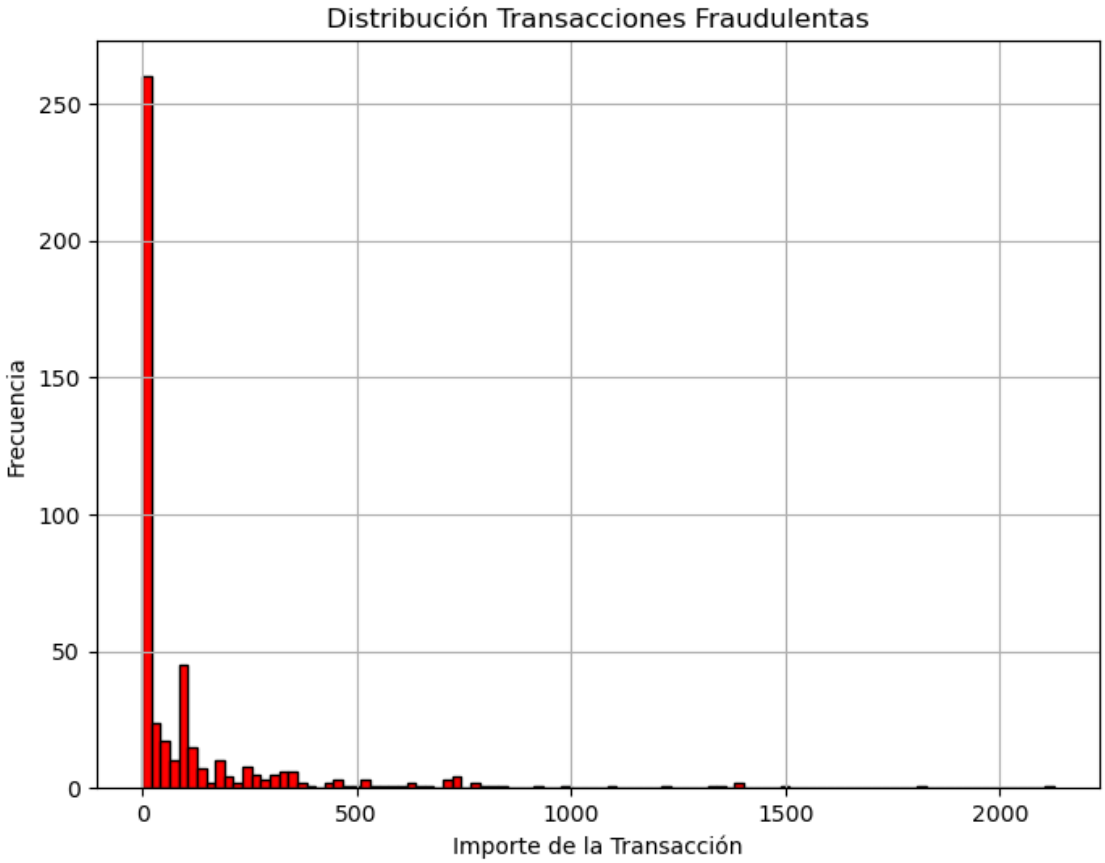

Haz clic aquí para obtener una pista

Para visualizar la distribución de los importes de las transacciones fraudulentas, deberás filtrar el dataset para que contenga únicamente las transacciones fraudulentas (aquellas donde «Class» es igual a 1) y, después, usar un histograma para representar la distribución de los valores de la columna «Amount» de los datos filtrados.

1.1 Desarrollo y evaluación de modelos

1.1.1 Separa del dataset

[43]:
```
# Crear el dataframe
X = dataset.drop('Class', axis=1)  # Todas las columnas excepto 'Class'
y = dataset['Class']  # Solo la columna 'Class'

# Dividir los datos en entrenamiento (80 %) y evaluación (20%)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
↪random_state=42)

# Imprimir las dimensiones de los datos divididos
```

```
print(f"Datos de entrenamiento - X_train: {X_train.shape}, y_train: {y_train.
 ↪shape}")
print(f"Datos de prueba - X_test: {X_test.shape}, y_test: {y_test.shape}")
#Uso print(f"..." )
#El método shape de pandas se utiliza para verificar las dimensiones de los␣
 ↪conjuntos resultantes (número de filas y columnas).
```

```
Datos de entrenamiento - X_train: (226980, 30), y_train: (226980,)
Datos de prueba - X_test: (56746, 30), y_test: (56746,)
```

Haz clic aquí para obtener una pista

Una vez que tegas este dataset, puedes utilizar la biblioteca scikit-learn para separar los da

Primero, puedes crear un dataframe de pandas «X» con todas las columnas excepto la columna «Cl

A continuación, pueder usar la función train_test_split() para separar los datos en grupos de

La función train_test_split() devuelve cuatro variables: X_train, X_test, y_train y y_test. X_

Ten en cuenta que es importante dividir los datos en grupos de entrenamiento y de evaluación p

1.1.2 Crea y evalúa los modelos

[47]:
```
#Transformar los datos para mejorar el rendimiento de ciertos modelos como la␣
 ↪Regresión Logística y SVM
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
#Crear una instancia de RandomForestClassifier
random_forest_model = RandomForestClassifier(max_depth=150, random_state=42)
#Entrenar el modelo
random_forest_model.fit(X_train_scaled, y_train)
#Predicciones sobre Prueba
y_pred = random_forest_model.predict(X_test_scaled)
#Evaluar el rendimiento
classificacion_rep = classification_report(y_test, y_pred)
accuracy = accuracy_score(y_test, y_pred)
# Mostrar el informe de clasificación y la precisión
print("Informe de clasificación:")
print(classificacion_rep)
print(f"\nExactitud del modelo: {accuracy * 100:.2f}%")
#accuracy por 100 convierte este valor decimal en un porcentaje.
#.2f significa que el número será mostrado como un número de punto flotante con␣
 ↪2 decimales.
```

```
Informe de clasificación:
              precision    recall  f1-score   support
```

```
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56656
           1       0.97      0.73      0.84        90

    accuracy                           1.00     56746
   macro avg       0.99      0.87      0.92     56746
weighted avg       1.00      1.00      1.00     56746


Exactitud del modelo: 99.95%
```

Haz clic aquí para obtener una pista

```
Debes haber importado las bibliotecas y clases necesarias, tales como la clase RandomForestCla

Una vez hayas hecho esto, podrás crear una instancia de la clase RandomForestClassifier config

A continuación, puedes utilizar el modelo entrenado para hacer predicciones sobre los datos de

Después, puedes utilizar la función classification_report() para mostrar en la pantalla un res

Finalmente, podrás mostrar la exactitud el modelo en forma de porcentaje; utiliza el operador *
```